



湖南大学
HUNAN UNIVERSITY

《基于 GNN 与多策略搜索算法的 TSP 求解方法研究》 最优化课程报告

学院： 数学学院

专业： 数学与应用数学专业

学号： 202210040323

姓名： 田展铭


2025 年 5 月 19 日

目录

1	摘要	1
2	引言	1
3	图神经网络与 TSP 建模	2
3.1	图神经网络基本原理	2
3.2	TSP 问题的图建模方式	2
3.3	数据集和数据处理	2
3.4	实验效果与初步分析	3
4	局部搜索方法与 GNN 的结合	4
4.1	Beam Search 原理与在 TSP 上的应用	4
4.2	2-opt 算法及其与 Beam Search 的联合策略	4
4.3	实验设置与性能评估	5
5	基于 GNN 引导的 OR-Tools 全局优化方法	6
5.1	方法概述	6
5.2	算法流程	6
5.3	实验结果	6
5.4	方法优势分析	7
6	实验分析与比较	7
7	应用与展望	8
7.1	中国的省级行政区首府最短路径	8
7.2	未来研究方向展望	8
7.2.1	基于强化学习的策略优化	8
7.2.2	结合 A* 搜索的启发式控制路径搜索	9
	参考文献	9

1 摘要

旅行商问题 (TSP) 作为经典的 NP 难问题, 一直是组合优化研究的重要对象。近年来, 图神经网络 (GNN) 在图结构数据上的建模能力使其成为求解 TSP 的新兴方法。本文提出一种结合图神经网络、局部搜索与全局优化的方法来求解 TSP 问题。首先, 利用 GNN 从城市图中学习最佳路径, 然后输出每条边的概率; 接着引入 Beam Search 与 2-opt 算法对 GNN 输出的概率进行局部优化得到一条路径; 最后使用 Google OR-Tools 中提供的整数线性规划 (ILP) 方法对结果进一步精调。通过在多个 TSP 实例上的实验表明, 该混合方法在保证求解质量的同时, 兼顾了效率与可扩展性, 具有较好的实际应用潜力。



2 引言

旅行商问题 (Traveling Salesman Problem, TSP) 是组合优化领域最具代表性的问题之一, 目标是在访问每个城市仅一次的前提下, 找到一条总距离最短的回路。TSP 广泛应用于物流配送、芯片设计、路径规划等多个领域。

传统上, TSP 主要通过精确算法 (如分支定界、动态规划) 和启发式/元启发式算法 (如贪心、遗传算法、模拟退火) 进行求解。然而, 近年来图神经网络 (Graph Neural Networks, GNNs) 的快速发展, 为组合优化问题的求解带来了新的思路。GNN 能够有效建模图结构, 并在节点之间进行信息传播, 适合用于表达 TSP 中的城市关系。

尽管 GNN 具备强大的表达能力, 但由于其生成解的方式通常是概率上的结果 (直接生成路径可能导致泛化性能很差), Senem Isik 和 Michael Atkin 利用 Beam Search 得到了一条路径, 但他们得到的结果往往只是一个局部最优解。^[1] 本文一是使用局部搜索算法 2-opt, 用于细化 GNN 生成的路径; 二是全局优化策略, 使用 Google OR-Tools 提供的整数线性规划模块进一步提升路径质量。通过这种 “GNN 生成 + 局部改进 + 全局调优” 的混合策略, 我们在多个 TSP 实例上实现了高效而准确的求解效果。

本文的主要贡献包括:

- 复现了 Senem Isik 和 Michael Atkin 利用 GNN 与 Beam Search 得到一条初始化路径;
- 利用 2-opt 对初始化路径进行一个局部优化, 得到一个局部最优解

- 利用 OR-Tools 中的 ILP 模型进一步精调 GNN 初解，提升求解精度；

接下来的章节将依次介绍所使用的 GNN 模型原理、各类搜索算法及其实验效果，最后综合分析其在 TSP 求解中的表现。

3 图神经网络与 TSP 建模

3.1 图神经网络基本原理

图神经网络 (Graph Neural Network, GNN) 是一类专门用于处理图结构数据的神经网络模型。与传统神经网络不同，GNN 能够利用节点之间的连接信息进行学习，通过“消息传递” (message passing) 机制更新节点表示。[2] 在一个标准的 GNN 框架中，节点的表示通过其邻居节点的特征聚合得到：

$$h_v^{(l)} = \sigma \left(W^{(l)} \cdot \text{AGGREGATE} \left(\{h_u^{(l-1)} | u \in \mathcal{N}(v)\} \right) \right) \quad (3.1)$$

其中， $h_v^{(l)}$ 表示第 l 层中节点 v 的表示， $\mathcal{N}(v)$ 是节点 v 的邻居集合， $\text{AGGREGATE}(\cdot)$ 表示聚合函数（如平均、最大、注意力机制等）， σ 是激活函数， $W^{(l)}$ 是可训练权重矩阵。

3.2 TSP 问题的图建模方式

图神经网络 (GNN) 具有广泛的适应性，能够处理多种类型的图结构数据。例如，在视觉任务中，输入可以是一个像素组成的网格图；而在路径优化类问题中，输入往往为非规则的加权图。GNN 对这些图结构均具有良好的表达和处理能力，特别适合处理旅行商问题 (TSP) 这类本质上基于图的组合优化问题。

在 TSP 中，我们可以自然地将城市建模为图中的节点，将城市之间的路径视为边。具体而言，TSP 问题可建模为一个完全图 $G = (V, E)$ ，其中：

- 每个节点 $v_i \in V$ 表示一个城市；每条边 $e_{ij} \in E$ 连接城市 i 与城市 j ，并具有一个正权值，表示两城市之间的欧几里得距离；
- 整张图是完全连接的，即任意两城市之间都存在一条边。

在图神经网络的建模过程中，该图结构可作为输入直接传递给模型。节点的初始特征可包括城市的二维坐标信息，或者使用全零向量初始化，再通过多层 GNN 学习表示；边的权重则作为边的附加特征，用于辅助图卷积或注意力计算。GNN 通过消息传递机制逐步更新每个 GNN 节点的嵌入表示，使其融合周围邻居的结构和距离信息。

3.3 数据集和数据处理

为了训练和评估的性能，使用了公开的使用 Concorde TSP 生成的数据集，数据集 中的数据从单位平方区域 $[0, 1]^2$ 中均匀随机采样 n 个节点，表示 n 个城市的二维坐标。

该区域保证了节点分布的均匀性与规模一致性，本数据集包含 $n = 10, 30, 50, 100$ 等和相应的最优路径。

为了兼顾效率和泛化性能，我们训练了 $n = 10, 30$ 的情况，实验数据显示泛化性能良好，但也显示了：算法的好坏与模型关系不大，后续的搜索算法更为重要！

3.4 实验效果与初步分析

$n = 30$ 时，训练时 Loss 图，出现了震荡现象，显示本次训练的步长过大，但即便如此，模型的泛化性能还是不错的。




图 3.1 Loss Curve

针对 $n = 10$ 和 $n = 30$ 训练出的 GNN 模型在具体实验数据上的表现，为概率热图。从结果可以看出，本文训练的 GNN 模型只能输出概率，而不能给出具体的路径，下面我们将结合具体的搜索算法给出相应的初始化路径。




图 3.2 Heat map

4 局部搜索方法与 GNN 的结合

4.1 Beam Search 原理与在 TSP 上的应用

Beam Search 是一种启发式宽度受限搜索算法，常用于序列生成问题。在 TSP 中，其主要思想是：从初始节点出发，每一步保留路径代价最小的 k 个候选部分路径（即 beam），并不断扩展，最终输出总代价最小的完整路径。

其搜索过程可描述如下：

1. 初始化时，将所有可能的起始节点作为初始路径；
2. 每一步扩展当前 beam 中的每条路径到尚未访问的节点，计算所有扩展后的路径代价；
3. 从所有扩展路径中选取代价最小的前 k 条路径作为新的 beam；
4. 重复上述过程直到生成完整路径；
5. 返回 beam 中代价最小的一条路径。

4.2 2-opt 算法及其与 Beam Search 的联合策略

2-opt 是一种经典且高效的局部路径优化算法，其基本操作是反转路径中的一段子序列，以减少路径长度。具体而言，2-opt 每次选择两条不相交的边 $(i, i+1)$ 和 $(j, j+1)$ ，若交换后能减少总路径长度，则进行边替换：

$$\text{if } d(v_i, v_{i+1}) + d(v_j, v_{j+1}) > d(v_i, v_j) + d(v_{i+1}, v_{j+1}), \text{ then perform swap} \quad (4.1)$$

该操作可反复执行，直到无法再通过边交换获得更优路径为止。

为了结合 Beam Search 与 2-opt，我们采用以下联合策略：

- 首先使用 GNN 生成路径概率；
- 其次使用 Beam Search 生成初始路径；
- 对初始路径应用 2-opt 优化，获得局部最优；

该方法同时利用了 GNN 的结构学习能力、Beam Search 的探索性以及 2-opt 的快速局部收敛性，能够实现高效的近似优化。

4.3 实验设置与性能评估

我们在 TSP 数据集上评估了此算法的性能，以下为部分实验结果（10 点和 30 点城市）最短路径，beam search 生成路径，2-opt 优化路径：




图 4.1 $n = 10$, beamsize = 8




图 4.2 $n = 30$, beamsize = 8




图 4.3 $n = 30$, beamsize = 8

从实验结果可以看出，在 n 较小时 beam search 和 2-opt 都能达到较好的效果； n 较大时，beam search 生成的初始路径往往效果较差，而 2-opt 可以做到不错的优化，但还不是最佳路径，陷入了局部最优点。接下来我们将结合全局搜索算法给出全局最优。

5 基于 GNN 引导的 OR-Tools 全局优化方法

5.1 方法概述

传统的全局优化方法如整数线性规划 (ILP) 在 TSP 问题中可以提供精确解,但在大规模图上计算成本极高。为兼顾效率与精度,本文引入一种结合图神经网络 (GNN) 与 OR-Tools 的混合优化策略。

该方法首先通过 GNN 预测图中边属于最优路径的概率,筛选出高概率子图以缩小搜索空间,再调用 OR-Tools 求解器在该稀疏图中精确搜索最优路径。此策略既利用了学习模型的预测能力,又保留了组合优化算法在子空间中的精确性。


5.2 算法流程

该方法可概括为以下三个主要步骤:

1. **边概率筛选:** 使用训练好的 GNN 模型对图中的每条边进行概率预测。仅保留概率排名前 *keep_ratio* (如 20%) 的边构成候选子图。
2. **构建稀疏距离矩阵:** 保留边的距离按欧几里得公式计算,未被保留的边赋予极大权重 (如 10^6),从而在优化过程中主动避免选择这些边。为了适配 OR-Tools 的整数输入要求,所有距离乘以 10^4 并向下取整。
3. **OR-Tools 精确求解:** 在构建好的稀疏图上使用 OR-Tools 的 RoutingModel 进行路径搜索。设置求解参数包括:
 - 初始解策略: PATH_CHEAPEST_ARC
 - 元启发式策略: GUIDED_LOCAL_SEARCH

5.3 实验结果

在 *keep_ratio*=0.4, *time_limit*.FromSeconds(5) 的情况下,基本能搜索出最优解,个别情况需调大比例或增加时长。



5.4 方法优势分析

- **效率提升：**GNN 概率筛选显著减少了搜索空间，使 OR-Tools 能够在较小时间内完成优化。
- **精度保证：**保留概率高的边基本覆盖了最优路径，能搜索到全局最优。
- **灵活性强：**通过调整保留比例 *keep_ratio* 可平衡精度与计算代价；即使 GNN 模型训练的不那么好也没关系。

通过结合神经网络与传统优化器的优势，该策略在实际任务中表现出良好的速度—精度折中能力，是经典 TSP 求解方案的重要补充。

6 实验分析与比较

我们在 30 个点的测试数据集数据集上评估该方法性能，与完整图求解器进行比较。选了 3 个有代表性的样本如下表所示：

注：OR-Tools 在规定时间内，找到最优路径之后仍会继续搜索，故设置了 5s 的时间限制，大部分都能在 5s 内求解，可基本认为 OR-Tools (subgraph) 的求解时长为 5s。

样本	方法	平均路径长度	平均运行时间（秒）
Sample 1	Ground Truth	4.4739	
	Beam Search	6.0716	0.1721
	Beam + 2-opt	5.0510	0.1966
	OR-Tools (subgraph)	4.4739	5.0123
Sample 2	Ground Truth	4.4710	
	Beam Search	5.9851	0.0199
	Beam + 2-opt	5.3111	0.0469
	OR-Tools (subgraph)	4.4710	5.0097
Sample 3	Ground Truth	4.2417	
	Beam Search	5.4201	0.0187
	Beam + 2-opt	4.6458	0.0313
	OR-Tools (subgraph)	未能求解	未能求解

表 6.1 优化方法的性能比较 ($n = 30$)

我们可以下结论在精度要求不高的情况下，可以选择 2-opt 效率非常高；在要求严格全局最优的情况下，选择 OR-Tools (subgraph)，在控制好 *keep_ratio*, *time_limit.FromSeconds()* 这两个参数的情况下，也是十分高效的。

7 应用与展望

7.1 中国的省级行政区首府最短路径

通过我们的混合方法求得最短路径为：

中国地图




图 7.1 省级行政区首府最短路径

7.2 未来研究方向展望

尽管本文所提出的 GNN 结合局部与全局搜索的混合方法在 TSP 求解中取得了良好的效果，但仍有诸多值得进一步探索的方向。特别是在强化学习和启发式搜索融合方面，未来可以从以下两个角度拓展研究：

7.2.1 基于强化学习的策略优化

当前 GNN 模型主要依赖监督信号（如 Concorde 生成的最优路径）进行训练，这在一定程度上限制了其对新规模或复杂图结构的泛化能力。未来可以引入强化学习（Reinforcement Learning, RL）框架，使模型能够在无监督或弱监督的环境下通过与路径优化环境的交互自动学习策略。

例如，可以借助策略梯度方法（如 REINFORCE）或基于值函数的方法（如 Actor-Critic），将 GNN 作为策略网络输出城市访问顺序，并根据路径长度构建奖励函数，从而实现端到端的路径优化。此类方法已在 Pointer Network 和 NeuroCOMB 等工作中展示出较强的潜力。通过与环境的反复交互，模型有望学会跨规模泛化的搜索策略，而非依赖固定的训练标签。

此外，引入元强化学习（Meta-RL）或分层强化学习结构，也可能使模型在更大规模图上具有更高的适应性与学习效率。

7.2.2 结合 A* 搜索的启发式控制路径搜索

另一值得探索的方向是将传统的 A* 搜索算法与神经网络模型相结合。A* 搜索以其启发式代价估计函数（heuristic function）而著称，在路径规划中表现出色。然而，手工设计的启发函数通常难以适配不同图结构。未来可以考虑使用 GNN 模型学习图中每个节点或边的“启发值”，作为 A* 搜索的估值函数（即 $f(n) = g(n) + h(n)$ 中的 $h(n)$ 部分），实现神经引导的 A* 搜索（Neural-guided A*）。

这种方法的核心在于：GNN 通过端到端训练学习图结构的全局信息，为 A* 提供更准确的路径估计值，从而减少无效扩展，提高搜索效率。相比于 Beam Search 仅保留若干路径，A* 结合代价与启发式函数进行优先级排序，可能更适合大规模图的搜索空间控制。

进一步地，可以将 A* 与强化学习策略结合，使搜索算法在执行过程中不断自适应地调整启发函数，形成动态的路径规划策略。

参考文献

- [1] M. Atkin. Tackling the traveling salesman problem with graph neural networks, 2023. URL <https://medium.com/stanford-cs224w/tackling-the-traveling-salesman-problem-with-graph-neural-networks-b86ef4300c6e>.
- [2] B. Sanchez-Lengeling, E. Reif, A. Pearce, and A. B. Wiltschko. A gentle introduction to graph neural networks, 2021. URL <https://distill.pub/2021/gnn-intro/>.